Python を用いた画像処理・機械学習経験（実装概要）

1. 概要

航空画像 3 クラス（airplane / denseresidential（高密度住宅）/ beach）を対象に、色情報とテクスチャ情報が分類性能に与える影響を比較する目的で、Python（Pandas, NumPy, scikit-learn, scikit-image, Pillow）を用いて特徴量抽出から分類モデルの学習・評価までの一連のパイプラインを実装した。

特徴量は RGB 統計量(各チャネルの平均値･標準偏差)、および GLCM(contrast, energy, homogeneity, correlation）の 4 種類のテクスチャ特徴量を抽出し、**RGB のみ / GLCM のみ / RGB＋GLCM** の 3 構成で比較した。

分類モデルには以下の 2 手法を使用した。

- Support Vector Machine（kernel="rbf", C=1.0, gamma="scale"）
- Random Forest（n_estimators=100）

SVM には StandardScaler による標準化を適用した。評価には Stratified 5-fold Cross Validation を用い、乱数シードを変更して 20 回反復し、Accuracy と F1-score の平均値および標準偏差を算出した。

また、全予測結果を統合した混同行列を作成し、誤分類傾向を分析した。

2. 結果

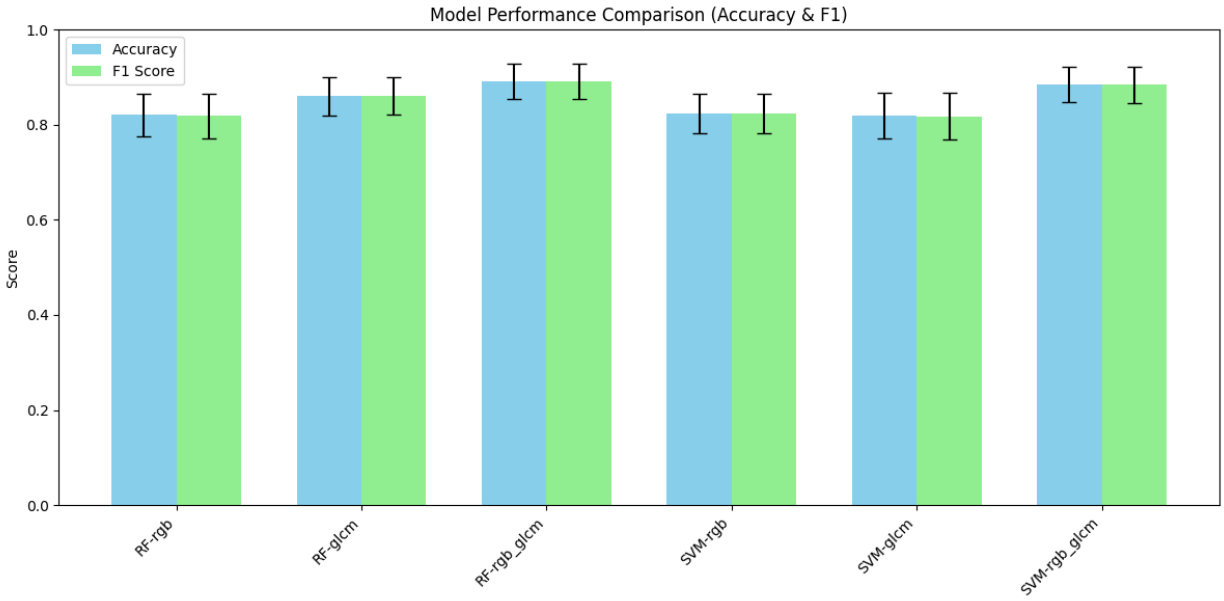

図 1：各特徴量構成および分類モデルにおける Accuracy/F1-score

図 1 に、各特徴量構成および分類モデルにおける Accuracy と F1-score を示す。 Random Forest では RGB 特徴量単体よりも GLCM 特徴量単体の方が高い精度と安定性を示した。一方、SVM では RGB と GLCM の性能差は小さく、GLCM の分散がやや大きい結果となった。

RGB と GLCM を組み合わせた場合、両モデルで Accuracy・F1-score が向上し、複数種類の特徴量を統合することが分類性能の向上に寄与することが確認された。

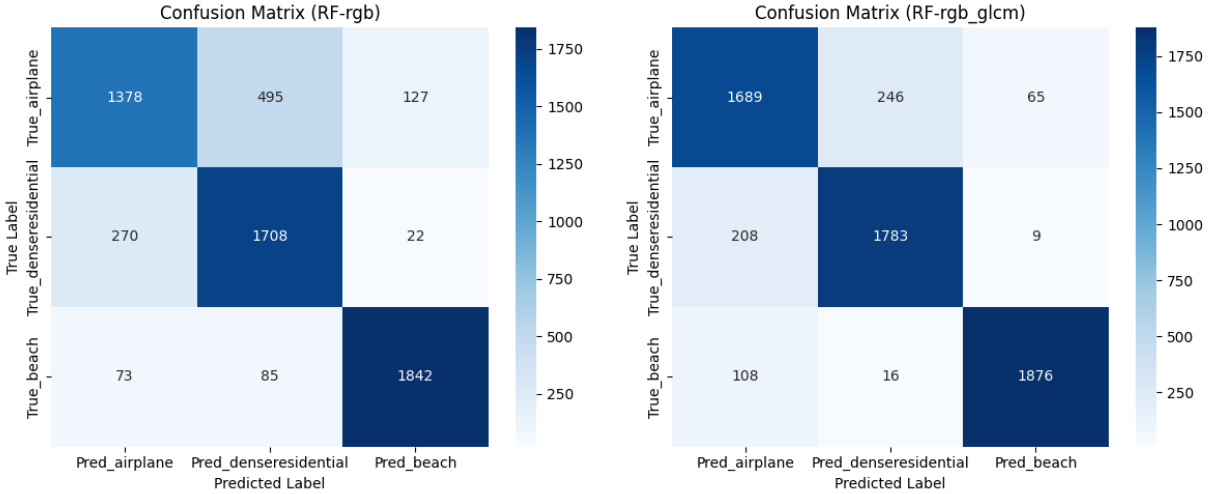

図 2・図 3：混同行列（RF-RGB/RF-RGB＋GLCM）

図 2 および図 3 に、Random Forest を用いた場合の混同行列を示す。 RGB のみを用いた場合、airplane と denseresidential の誤分類が多く見られた。GLCM を併用することでこの誤分類の多くが改善され、住宅地の規則的な構造や空港周辺の明暗差といったテクスチャ情報が識別に寄与したと考えられる。

一方で、beach→airplane の誤分類はわずかに増加した。これは、砂浜の均質なパターンが、テクスチャ特徴の追加により駐機場などと類似した質感として扱われた可能性がある。

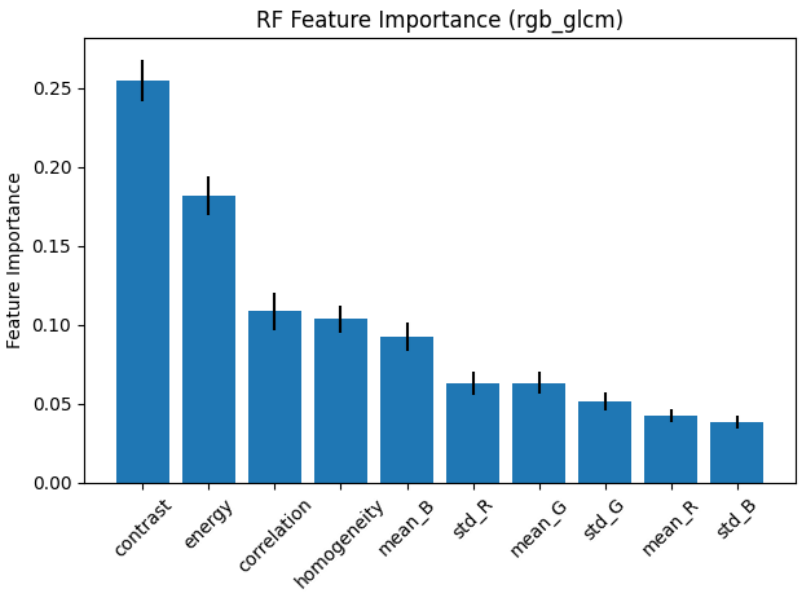

図 4：各特徴量の重要度（RGB&GLCM）

図 4 に、RGB＋GLCM を用いた Random Forest の特徴量重要度を示す。contrast と energy の寄与が特に高く、テクスチャ特徴が分類に強く影響していることが確認された。住宅地では建物配置による規則的パターン、空港では飛行機や影・コンクリート面の明暗差が特徴として捉えられたと考えられる。

3. 考察と改善案

本実験では、RGB 統計量と GLCM テクスチャ特徴を組み合わせることで分類性能が向上することを確認した。特に、airplane と denseresidential の誤分類は大幅に改善されたが、完全には解消されていない。また、beach→airplane の誤分類は一部で増加した。

これは、RGB のみで容易に識別できていたクラスが、テクスチャ特徴の追加により別クラスと質感が近づいてしまったことが原因と考えられる。これらの結果から、今回の特徴量のみでは表現力に限界があり、以下の改善が有効と考えられる。

- HOG などの局所形状特徴を導入し、物体構造情報を追加する
- GLCM の方向依存性を活かし、複数方向の特徴量を個別に利用する
- 特徴量選択やハイパーパラメータ探索によるモデル最適化を行う

これらの改善により、さらなる識別性能の向上が期待できる。また、テクスチャ特徴が有効であった点は、医療画像における組織構造の識別にも通じる部分があり、医療画像解析への応用可能性も示唆される。